Project 1：语音端点检测

523030910243 李颢辰

1. 问题分析与符号定义

语音端点检测的目标是在给定语音序列中判定每一帧是否属于语音。设离散语音信号为 $x[n], n = 0, \ldots, N-1$，采样率记为 $f_s = 16$ kHz。所有实验统一采用帧长 $T_w = 32$ ms、帧移 $T_h = 8$ ms，与标签生成规则保持一致。

1.1. 问题表述

设每帧长度和帧移对应的采样点数分别为 $L = \mathrm{round}(f_s T_w)$、$H = \mathrm{round}(f_s T_h)$。第 t 帧信号记为

$$\boldsymbol{x}_t = [x[tH], x[tH+1], \ldots, x[tH+L-1]]^\top \in \mathbb{R}^L, \quad (1)$$

并乘以窗函数 $w[\cdot]$ 得到分析帧

$$\tilde{\boldsymbol{x}}_t = \boldsymbol{x}_t \odot \boldsymbol{w}. \quad (2)$$

对应的帧级标签记为 $y_t \in \{0, 1\}$，其中 $y_t = 1$ 表示语音帧，$y_t = 0$ 表示非语音帧。端点检测可统一写为学习如下映射关系：

$$s_t = f(\boldsymbol{f}_t), \qquad \hat{y}_t = g(s_t), \quad (3)$$

其中 $\boldsymbol{f}_t$ 为第 t 帧特征，s_t 为该帧得分，$\hat{y}_t$ 为最终分类结果。

1.2. 符号定义

表 1: 统一符号定义

符号	含义
$\boldsymbol{x}_t$	第 t 帧时域信号
$\tilde{\boldsymbol{x}}_t$	加窗后的第 t 帧信号
L, H	帧长与帧移对应的采样点数
$\boldsymbol{f}_t$	第 t 帧最终特征向量
$y_t, \hat{y}_t$	真实标签与预测标签
s_t	语音得分或后验概率
τ, τ_h, τ_l	单阈值、双阈值中的高低阈值
$\mathcal{D}_{\text{tr}}, \mathcal{D}_{\text{dev}}, \mathcal{D}_{\text{te}}$	训练、开发、测试集合

1.3. 标签与评测

数据集原始标签以语音起止时间段给出，实验中先将其转为帧级标签，再与特征帧数对齐；测试阶段则将帧级预测结果重新转换为时间段输出。因此，模型训练、阈值选择和指标统计均在帧级空间完成。在数据使用上，Task1 仅在 $\mathcal{D}_{\text{dev}}$ 上进行阈值调整并给出最终结果，再将同一组参数用于 $\mathcal{D}_{\text{te}}$；Task2 使用 $\mathcal{D}_{\text{tr}}$ 学习 GMM/DNN 模型参数，再在 $\mathcal{D}_{\text{dev}}$ 上进行阈值选择与性能统计，最后在 $\mathcal{D}_{\text{te}}$ 上生成测试结果。

2. Task1：基于线性分类器和语音短时能量的简单语音端点检测算法

2.1. 数据预处理及特征提取

Task1 的处理流程为：分帧、末帧零填充、可选加窗、提取短时特征、逐帧判决。分帧用于把非平稳语音近似为短时平稳信号；末帧补零保证数据格式对齐，每一帧的长度相等；Hamming 窗可减弱帧边界处的不连续性，从而降低频谱泄漏。本实验同时比较无窗与 Hamming 窗，并提取四类短时特征组成特征向量

$$\boldsymbol{f}_t^{(1)} = [\bar{E}_t, \bar{Z}_t, \bar{S}_t, \bar{P}_t]^\top. \quad (4)$$

2.1.1. 短时能量

概念：短时能量描述一帧语音波形在短时间内的幅度强弱，是最直接的时域能量统计量。**听觉直观**：能量较高的帧通常听起来更响，更可能处在语音主体部分；静音、停顿或背景弱噪声通常能量较低。**公式定义**：

$$E_t = \log\left(\sum_{m=0}^{L-1} \tilde{x}_t^2[m] + \varepsilon\right), \quad (5)$$

其中 ε 为数值稳定项。随后按整段语音做标准化，

$$\bar{E}_t = \frac{E_t - \mu_E}{\sigma_E + \varepsilon}. \quad (6)$$

2.1.2. 过零率

概念：过零率描述一帧波形穿越零幅度轴的频繁程度，反映信号符号变化的快慢。**听觉直观**：过零率较高的片段往往更尖锐或噪声感更强，如摩擦音、清音或部分背景噪声；有声元音等稳定浊音的过零率通常较低。**公式定义**：

$$Z_t = \frac{1}{2(L-1)} \sum_{m=0}^{L-2} \left|\mathrm{sgn}(\tilde{x}_t[m+1]) - \mathrm{sgn}(\tilde{x}_t[m])\right|. \quad (7)$$

$$\bar{Z}_t = \frac{Z_t - \mu_Z}{\sigma_Z + \varepsilon}. \quad (8)$$

2.1.3. 短时频谱

概念：短时频谱描述一帧信号在不同频率上的幅度分布，本实验使用每帧 log-magnitude 谱均值作为一维频域统计量。**听觉直观**：频谱能反映声音的明暗和频率成分分布；语音通常具有较稳定的频带结构，而静音或部分噪声的频谱形态更分散或更弱。**公式定义**：设第 t 帧的离散频谱为

$$X_t[k] = \sum_{m=0}^{L-1} \tilde{x}_t[m] \exp\left(-j2\pi km/L\right), \quad (9)$$

则短时频谱统计量定义为

$$S_t = \frac{1}{K_s} \sum_{k=0}^{K_s-1} \log\left(1 + |X_t[k]|\right), \qquad \bar{S}_t = \frac{S_t - \mu_S}{\sigma_S + \varepsilon}. \quad (10)$$

2.1.4. 基频

概念：基频 F_0 描述有声语音声带周期振动的基本频率，本实验用自相关峰值对应的频率作近似估计。**听觉直观**：基频直接对应主观音高；浊音通常具有稳定周期性和较明确的音高，清音、噪声或静音则往往没有可靠基频。**公**

式定义：先计算帧内自相关

$$R_t[\ell] = \sum_{m=0}^{L-1-\ell} \tilde{x}_t[m]\tilde{x}_t[m+\ell], \tag{11}$$

并在 $f_{\min} = 60$ Hz、$f_{\max} = 400$ Hz 对应的滞后区间 $\ell \in [\lfloor f_s/f_{\max} \rfloor, \lfloor f_s/f_{\min} \rfloor]$ 内寻找峰值：

$$\ell_t^\star = \arg\max_{\ell} R_t[\ell]. \tag{12}$$

$$P_t = \begin{cases} f_s/\ell_t^\star, & R_t[\ell_t^\star]/R_t[0] \geq 0.3, \\ 0, & \text{otherwise}. \end{cases} \tag{13}$$

随后做标准化 $\bar{P}_t = (P_t - \mu_P)/(\sigma_P + \varepsilon)$。

2.2. 算法描述

2.2.1. 线性打分与双阈值判决

Task1 的帧级得分写为

$$s_t = \boldsymbol{\omega}^\top [\bar{E}_t, -\bar{Z}_t, \bar{S}_t, \bar{P}_t]^\top. \tag{14}$$

其中 $\boldsymbol{\omega} = [\omega_E, \omega_Z, \omega_S, \omega_P]^\top$ 为可调权重；过零率项取负号，表示过高的符号变化率更可能对应噪声或非稳定语音。单特征实验可视为仅保留对应权重，组合特征实验则通过调整多项权重完成。在此基础上采用双阈值滞回判决，避免单阈值在边界处频繁抖动。记状态变量为 $q_t \in \{0, 1\}$，则

$$q_t = \begin{cases} 1, & s_t > \tau_h \text{ 且} q_{t-1} = 0, \\ 0, & s_t < \tau_l \text{ 且} q_{t-1} = 1, \\ q_{t-1}, & \text{其他情况}. \end{cases} \tag{15}$$

最终输出 $\hat{y}_t = q_t$。

阈值 (τ_h, τ_l) 在有标签数据上通过网格搜索确定：先在所有帧得分上取若干分位点作为候选集，再枚举 $\tau_l \leq \tau_h$ 的组合，以帧级准确率最高者作为最终参数。Task1 中阈值在 $\mathcal{D}_{\text{dev}}$ 帧级样本上估计，并用于得到 $\mathcal{D}_{\text{dev}}$ 最终结果。$\mathcal{D}_{\text{dev}}$ 评估阶段对二值输出再做一次长度为 50 的中值平滑，以削弱孤立误检。

伪代码说明：以下代码对应 Task1 的双阈值滞回判决与中值平滑流程。

```
def decode_task1(features, weights, tau_h, tau_l):
    energy, zcr, spectrum, pitch = features.T
    scores = (
        weights.energy * energy
        - weights.zcr * zcr
        + weights.spectrum * spectrum
        + weights.pitch * pitch
    )
    state, pred = 0, []
    for s in scores:
        if state == 0 and s > tau_h:
            state = 1
        elif state == 1 and s < tau_l:
            state = 0
        pred.append(state)
    return median_smooth(pred, kernel=50)
```

2.2.2. 测试阶段输出

未知标签端点检测说明：Task1 测试时不再重新选择阈值，而是复用 $\mathcal{D}_{\text{dev}}$ 上确定的 (τ_h, τ_l)，对未知标签的测试集语音依次执行分帧、特征提取、双阈值判决、中值平滑和语音区间合并。

具体地，模型先对未知语音得到逐帧预测 $\hat{y}_t$，再把连续满足 $\hat{y}_t = 1$ 的帧合并为一段语音。若语音段对应帧索引 $a, \ldots, b$，则用首尾帧中心时间近似端点，即 $(aH + L/2)/f_s$ 到 $(bH + L/2)/f_s$，最后按 ‘start,end start,end ...‘ 的格式输出。

伪代码说明：以下代码对应 Task1 在未知语音上的端点输出流程。

```
def infer_task1_unknown(waveform, weights, tau_h,
    tau_l):
    features = extract_task1_features(waveform)
    pred = decode_task1(features, weights, tau_h,
    tau_l)
    segments = frames_to_segments(pred, win=32ms,
    hop=8ms)
    return format_as_label(segments)
```

2.3. 实验结果

2.3.1. 实验指标

本任务主要从帧级分类质量和阈值相关性能两方面评价模型。所有指标均先将整个 $\mathcal{D}_{\text{dev}}$ 的逐帧预测结果与逐帧标签拼接，再统一统计。

- Accuracy: $\text{Acc} = (TP + TN)/(TP + TN + FP + FN)$，衡量整体判决正确率。
- Precision: $\text{Prec} = TP/(TP + FP)$，反映被判为语音的帧中有多少是真语音。
- Recall: $\text{Rec} = TP/(TP + FN)$，反映真实语音帧中有多少被正确检出。
- F_1 score: $F_1 = 2\text{PrecRec}/(\text{Prec} + \text{Rec})$，综合反映精确率与召回率的平衡。
- False Acceptance Rate: $\text{FAR} = FP/(FP + TN)$，表示把非语音误判为语音的比例。
- False Rejection Rate: $\text{FRR} = FN/(TP + FN)$，表示把语音误判为非语音的比例。
- AUC: ROC 曲线下的面积，反映不同阈值下 TPR 与 FAR 的整体表现，越大表示模型整体区分能力越强。
- EER: FAR 与 FRR 相等时的错误率，越小越好。

2.3.2. 实验配置

- 数据划分：Task1 仅使用 $\mathcal{D}_{\text{dev}}$ 进行权重配置比较、双阈值选择与性能统计，并将同一配置用于未知标签数据推理。
- 分帧参数：采样率 $f_s = 16$ kHz，帧长 $T_w = 32$ ms，帧移 $T_h = 8$ ms，因此 $L = 512$、$H = 128$。
- 特征：Task1 尝试使用短时能量，过零率，短时频谱和基频 4 种特征；下方表格中能量 & 过零率表示 $\boldsymbol{\omega} = [0.8, 0.2, 0, 0]^\top$，其中过零率以负权进入得分。
- 判决与后处理：在 $\mathcal{D}_{\text{dev}}$ 上搜索 (τ_h, τ_l)，采用双阈值滞回判决，并使用长度为 50 的中值平滑抑制孤立误检。

2.3.3. 结果分析

表 2: *Task1* $\mathcal{D}_{dev}$ 结果（%）

模型特征	窗函数	Acc	Prec	Rec	F_1	FAR	FRR	AUC	EER
能量	None	**95.12**	**96.76**	97.28	**97.02**	**14.49**	2.72	**96.64**	**8.34**
能量	Hamming	94.45	95.85	97.43	96.63	18.80	2.57	96.17	9.09
过零率	None	81.64	81.65	**99.98**	89.89	100.00	**0.02**	56.50	41.37
频谱	None	94.00	96.50	96.14	96.32	15.52	3.86	95.04	9.99
基频	None	81.67	81.79	99.76	89.89	98.85	0.24	50.33	44.69
能量 & 过零率	None	93.50	94.96	97.20	96.07	22.95	2.80	95.36	10.38
能量 & 过零率	Hamming	93.38	94.86	97.17	96.00	23.45	2.83	94.81	11.21

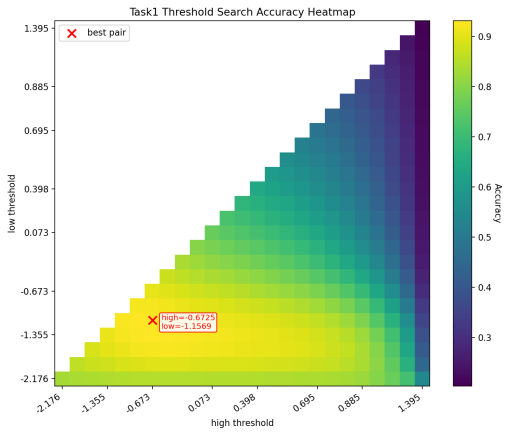

图 1: *Task1*（能量特征、无窗函数）双阈值网格搜索图，用于选择最优 τ_h, τ_l。

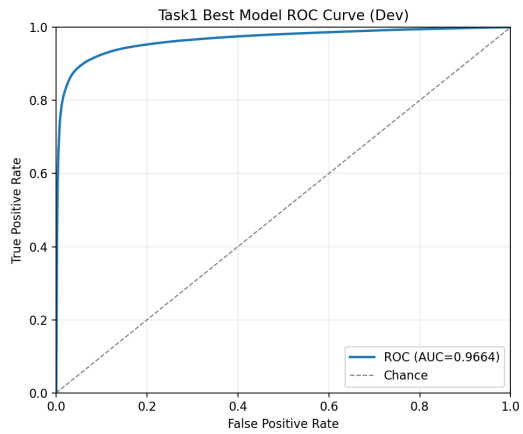

图 2: *Task1*（能量特征、无窗函数）$\mathcal{D}_{dev}$ *ROC* 曲线。

从表 2 可以看到，**能量特征在本任务中最有效**：无窗设置取得最佳 Acc/AUC/EER（95.12%/96.64%/8.34%）。加入 Hamming 窗后，性能略有下降，说明当前数据条件下，边界平滑收益不足以抵消能量判别力的损失。仅使用过零率或基频时，AUC 与 EER 明显恶化，表明二者单独作为主判别特征不稳定。并且可以观察到，仅使用过零率时选择出的最佳阈值接近所有帧得分的最低值，模型趋向于将绝大多数帧判定为语音帧以获得较高准确率，此时准确率主要反映原始帧中语音帧的占比。短时频谱特征表现介于二者之间，具备一定区分能力，但仍弱于纯能量。此外，能量与过零率按 0.8/0.2 加权后，两种窗设置均未超过纯能量，说明本实验下过零率带来的增益有限。综合考虑，Task1 最优配置为**能量特征 + 无窗 + 双阈值滞回判决**。且最终测试集的预测标签也是基于最优配置来进行。

3. Task2：基于统计模型分类器和语音频域特征的语音端点检测算法

3.1. 数据预处理及特征提取

Task2 采用频域特征。设静态谱特征为 $\boldsymbol{u}_t \in \mathbb{R}^K$，其取值可为 FBank 或 MFCC。首先以 32 ms 分析窗和 8 ms 帧移计算谱特征，再按配置拼接一阶或二阶差分：

$$\boldsymbol{g}_t = \begin{cases} [\boldsymbol{u}_t; \Delta\boldsymbol{u}_t], & \text{使用一阶差分}, \\ [\boldsymbol{u}_t; \Delta\boldsymbol{u}_t; \Delta^2\boldsymbol{u}_t], & \text{使用一阶与二阶差分}. \end{cases} \tag{16}$$

随后对每条语音做均值方差归一化（CMVN），并使用左右各 1 帧上下文进行拼接：

$$\boldsymbol{f}_t^{(2)} = [\boldsymbol{g}_{t-1}; \boldsymbol{g}_t; \boldsymbol{g}_{t+1}]. \tag{17}$$

因此，Task2 的最终输入既包含频谱形状信息，也包含局部动态变化信息。

3.1.1. *FBank*

概念：FBank 是 Mel 滤波器组上的对数能量，刻画每个感知频带内的谱能量分布。**听觉直观**：不同 Mel 频带能量的强弱对应声音在低频、中频和高频上的明暗与厚薄；语音段通常在若干语音相关频带上呈现稳定能量结构。**公式定义**：设第 t 帧的功率谱为 $|X_t[r]|^2$，第 k 个 Mel 滤波器为 $H_k[r]$，则

$$M_{t,k} = \log\left(\sum_r H_k[r]|X_t[r]|^2 + \varepsilon\right), \quad k = 1, \ldots, K. \tag{18}$$

3.1.2. *MFCC*

概念：MFCC 是对 Mel 频带对数能量再做离散余弦变换得到的倒谱系数，用较少维度描述语音谱包络。**听觉直观**：谱包络与音色、发音腔体形状密切相关；MFCC 去除了部分细碎谱细节，更强调稳定的音色结构。**公式定义**：

$$c_{t,q} = \sum_{k=1}^{K} M_{t,k} \cos\left[\frac{\pi q}{K}\left(k - \frac{1}{2}\right)\right], \quad q = 0, \ldots, K-1. \tag{19}$$

3.1.3. *差分特征*

概念：差分特征描述相邻帧之间声学特征的动态变化，补充静态谱特征无法直接表达的时间趋势。**听觉直观**：语音起止、音素转换和爆破音等都会带来明显的短时变化；差分项有助于捕捉这些“变化感”。**公式定义**：设差分窗口半宽为 R，则一阶差分定义为

$$\Delta\boldsymbol{u}_t = \frac{\sum_{r=1}^{R} r(\boldsymbol{u}_{t+r} - \boldsymbol{u}_{t-r})}{2\sum_{r=1}^{R} r^2}. \tag{20}$$

二阶差分由一阶差分再次差分得到，即 $\Delta^2\boldsymbol{u}_t = \Delta(\Delta\boldsymbol{u}_t)$。

伪代码说明：以下代码对应 Task2 的 FBank/MFCC、差分、CMVN 与上下文拼接流程。

```
def extract_task2_features(waveform, feature_type,
    use_delta2=False):
    static = fbank_or_mfcc(waveform, win=32ms, hop
    =8ms, dim=K)
    delta = compute_delta(static)
    feat = concat([static, delta], axis=1)
    if use_delta2:
        delta2 = compute_delta(delta)
        feat = concat([feat, delta2], axis=1)
    feat = cmvn(feat)
    return stack_context(feat, left=1, right=1)
```

3.2. 算法描述

3.2.1. *GMM 语音/非语音似然比模型*

GMM 方法分别对语音帧和非语音帧建模。设标准化后的特征为 $\boldsymbol{z}_t$，则训练两个类别条件密度 $p(\boldsymbol{z}_t|\mathcal{S})$ 和 $p(\boldsymbol{z}_t|\mathcal{N})$。语音类采用 4 分量对角协方差高斯，非语音类采用单分量高斯。训练方式为：先用 $\mathcal{D}_{\text{tr}}$ 全部帧估计标准化器，再按标签将标准化后的特征划分为语音帧与非语音帧，

分别独立拟合两类模型，并估计语音先验 $\rho = P(y=1)$。测试时计算带先验修正的对数似然比

$$\ell_t = \log p(\boldsymbol{z}_t|\mathcal{S}) - \log p(\boldsymbol{z}_t|\mathcal{N}) + \log \frac{\rho}{1-\rho}, \tag{21}$$

再经 Sigmoid 映射得到语音得分

$$s_t = \sigma(\ell_t). \tag{22}$$

得分 s_t 随后交由统一的阈值判决与平滑流程得到端点检测结果。

GMM 参数 $\{\pi_m, \boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m\}_{m=1}^{M}$ 使用 EM 算法估计，其中语音类与非语音类分别独立训练。下述伪代码写作通用协方差形式；对角协方差实现时只保留 $\boldsymbol{\Sigma}_m$ 的对角元素。

伪代码说明：以下代码对应 GMM 的 EM 参数估计与语音/非语音似然比打分流程。

算法 1 GMM 的 EM 参数估计与帧级打分

输入： 语音样本 $\mathcal{Z}_{\mathrm{S}}$、非语音样本 $\mathcal{Z}_{\mathrm{N}}$；混合数 $M_{\mathrm{S}} = 4, M_{\mathrm{N}} = 1$；待测帧 $\boldsymbol{z}_t$

输出： 类别 GMM 参数 $\lambda_{\mathrm{S}}, \lambda_{\mathrm{N}}$；语音得分 s_t

$\rho \leftarrow |\mathcal{Z}_{\mathrm{S}}|/(|\mathcal{Z}_{\mathrm{S}}| + |\mathcal{Z}_{\mathrm{N}}|)$
for $c \in \{\mathrm{S}, \mathrm{N}\}$ **do**
  初始化 $\lambda_c = \{\pi_m^{(c)}, \boldsymbol{\mu}_m^{(c)}, \boldsymbol{\Sigma}_m^{(c)}\}_{m=1}^{M_c}$
  repeat
    E-step: 对每个样本 $\boldsymbol{z}_i^{(c)}$ 与分量 m，计算责任度
$$\gamma_{im}^{(c)} = \frac{\pi_m^{(c)} \mathcal{N}(\boldsymbol{z}_i^{(c)}; \boldsymbol{\mu}_m^{(c)}, \boldsymbol{\Sigma}_m^{(c)})}{\sum_{j=1}^{M_c} \pi_j^{(c)} \mathcal{N}(\boldsymbol{z}_i^{(c)}; \boldsymbol{\mu}_j^{(c)}, \boldsymbol{\Sigma}_j^{(c)})}$$
    M-step: 更新有效样本数、权重、均值和协方差
$$N_m^{(c)} = \sum_i \gamma_{im}^{(c)}, \quad \pi_m^{(c)} = \frac{N_m^{(c)}}{N_c}$$
$$\boldsymbol{\mu}_m^{(c)} = \frac{1}{N_m^{(c)}} \sum_i \gamma_{im}^{(c)} \boldsymbol{z}_i^{(c)}$$
$$\boldsymbol{\Sigma}_m^{(c)} = \frac{1}{N_m^{(c)}} \sum_i \gamma_{im}^{(c)} (\boldsymbol{z}_i^{(c)} - \boldsymbol{\mu}_m^{(c)})(\boldsymbol{z}_i^{(c)} - \boldsymbol{\mu}_m^{(c)})^\top$$
  until 对数似然收敛或达到最大迭代轮数
end for
$\ell_t \leftarrow \log p(\boldsymbol{z}_t|\lambda_{\mathrm{S}}) - \log p(\boldsymbol{z}_t|\lambda_{\mathrm{N}}) + \log \frac{\rho}{1-\rho}$
$s_t \leftarrow \sigma(\ell_t)$

3.2.2. DNN 帧级分类模型

DNN 使用三层感知机完成逐帧二分类。输入为标准化后的频域特征，输出为语音后验概率。设上下文半宽为 C，静态特征维度为 K；仅使用一阶差分时输入维数为 $D = (2C+1)2K$，同时使用一阶与二阶差分时输入维数为 $D = (2C+1)3K$。本实验中 $C = 1$，超参数配置见第 3.3.2 节。模型输出经 Sigmoid 函数转为语音后验概率，在 $\mathcal{D}_{\mathrm{dev}}$ 上通过阈值搜索选择最优 τ，并使用长度为 10 的平滑核对预测序列做后处理。

$$\boldsymbol{f}_t^{(2)} \to \mathrm{Linear}(D, 256) \to \mathrm{ReLU} \to \mathrm{Linear}(256, 512) \to \mathrm{ReLU} \to \mathrm{Linear}(512, 1) \to \mathrm{Sigmoid} \to s_t$$

图 3: *Task2 中 DNN 的网络结构示意图*

伪代码说明：以下代码对应 DNN 帧级分类器的前向打分流程。

```python
def score_dnn(features, dnn):
    h = relu(linear(features, 256))
    h = relu(linear(h, 512))
    return sigmoid(linear(h, 1))
```

3.2.3. $\mathcal{D}_{dev}$ 阈值选择与 $\mathcal{D}_{te}$ 输出

Task2 在 $\mathcal{D}_{\mathrm{tr}}$ 上训练统计模型，在 $\mathcal{D}_{\mathrm{dev}}$ 上收集逐帧得分，并在 $[0.1, 0.9]$ 区间以 0.01 为步长搜索阈值，使 $\mathcal{D}_{\mathrm{dev}}$ 帧级准确率最大。

未知标签端点检测说明：模型训练完成后，未知标签语音按“特征提取–模型打分–阈值判决–平滑–区间合并”的流程输出端点。

$\mathcal{D}_{\mathrm{te}}$ 阶段复用该阈值，将二值预测序列平滑后再转换为连续时间段输出。换言之，对未知标签语音的推理流程为：提取频域特征、执行 CMVN 与上下文拼接、送入 GMM 或 DNN 得到逐帧得分、依据阈值完成二值化、进行中值平滑、最后合并为端点时间段。

伪代码说明：以下代码对应 Task2 在未知语音上的完整推理与端点输出流程。

```python
def infer_task2(waveform, model, tau):
    features = extract_task2_features(waveform, feature_type)
    scores = model.score_frames(features)
    pred = (scores >= tau)
    pred = median_smooth(pred, kernel=10)
    return frames_to_segments(pred, win=32ms, hop=8ms)
```

3.3. 实验结果

3.3.1. 实验指标

Task2 使用与 Task1 相同的评测指标。模型在 $\mathcal{D}_{\mathrm{tr}}$ 上训练，阈值选择、帧级指标和 ROC/AUC/EER 均在 $\mathcal{D}_{\mathrm{dev}}$ 上统一计算。

3.3.2. 实验配置

- 数据划分：使用 $\mathcal{D}_{\mathrm{tr}}$ 训练 GMM/DNN，在 $\mathcal{D}_{\mathrm{dev}}$ 上选择阈值并统计指标，未知标签数据复用该阈值输出端点。
- 声学特征：采样率 16 kHz，帧长 32 ms，帧移 8 ms；基础特征维度 $K = 40$，使用 CMVN、左右各 1 帧上下文，并比较 FBank/MFCC 及其差分组合，特征名中的 $+\Delta$ 与 $+\Delta^2$ 分别表示拼接一阶与二阶差分。
- GMM 配置：语音类使用 4 个对角协方差高斯分量，非语音类使用单个高斯分量；模型输入先由训练集估计标准化器。
- DNN 配置：Network1 为两层隐藏层 MLP（256/512）；批量实验配置中的 Network2 在隐藏层后加入 BatchNorm 与 Dropout。训练使用 Adam、学习率 10^{-3}、权重衰减 10^{-5}、batch size 为 5210，并采用 Focal Loss（$\alpha = 0.25, \gamma = 2.0$）。消融实验训练 10 轮，最终配置训练 40 轮。
- 判决与后处理：阈值在 $[0.1, 0.9]$ 内以 0.01 步长搜索，二值预测后采用长度为 10 的平滑核。

3.3.3. 结果分析

GMM 结果：GMM 中语音类使用 4 个对角协方差高斯分量，非语音类使用单个高斯分量。

表 3: *Task2 GMM $\mathcal{D}_{dev}$ 结果（%）*

特征	Acc	Prec	Rec	F_1	FAR	FRR	AUC	EER
FBank	93.11	98.18	92.83	95.43	7.68	7.17	96.08	7.35
FBank+Δ	94.53	**99.09**	93.99	96.47	**3.84**	6.01	97.10	4.98
FBank+$\Delta+\Delta^2$	95.61	98.85	95.61	97.20	4.95	4.39	96.99	**4.66**
MFCC	93.31	97.70	93.86	95.74	9.86	6.14	96.92	7.18
MFCC+Δ	**96.07**	98.22	**96.86**	**97.54**	7.84	**3.14**	**97.91**	4.94

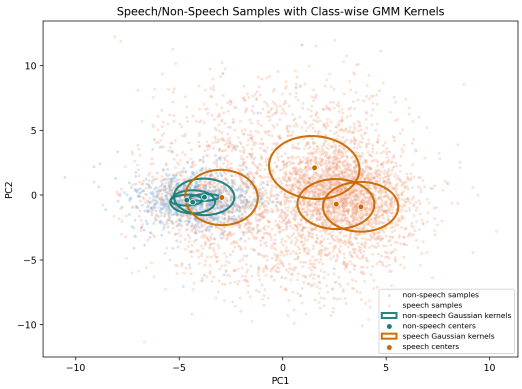

图 4: *GMM 最优配置（MFCC+Δ）的语音类混合分量诊断图。*

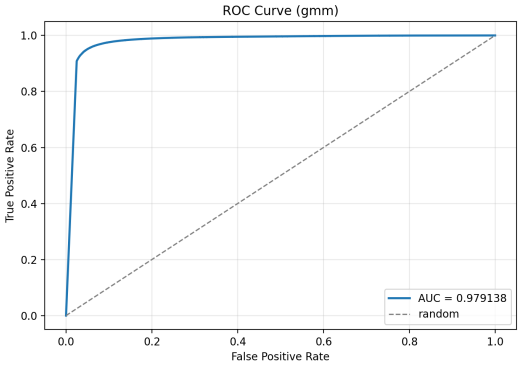

图 5: *GMM 最优配置（MFCC+Δ）的 $\mathcal{D}_{dev}$ ROC 曲线。*

从表 3 可以看到，MFCC+Δ 在 Acc、Recall、F_1、FRR 与 AUC 上最优，是 GMM 的综合最佳配置。FBank 保留更细粒度的滤波器组能量，在高维条件下可能增加 GMM 的建模难度；MFCC 主要保留谱包络信息，表示更紧凑，因此更符合 GMM 的高斯建模假设。

DNN 结果：DNN 对比 Network1 与 Network2 两种网络配置。受训练时间限制，消融实验均采用较轻量的训练设置。后续再对简单配置下表现较好的模型进行规模更大的实验。

表 4: *Task2 DNN $\mathcal{D}_{dev}$ 10 轮训练结果（%）*

网络	特征	Acc	Prec	Rec	F_1	FAR	FRR	AUC	EER
Network1	FBank	96.93	98.26	97.70	97.98	7.71	2.30	99.13	3.72
Network1	FBank+Δ	98.05	98.72	98.85	98.78	5.74	1.15	99.61	2.59
Network1	FBank+$\Delta+\Delta^2$	**98.14**	**98.78**	98.89	**98.84**	**5.44**	1.11	**99.63**	**2.47**
Network1	MFCC	96.59	98.26	97.26	97.76	7.67	2.74	98.93	4.02
Network1	MFCC+Δ	97.92	98.63	98.75	98.69	6.12	1.25	99.52	2.75
Network2	FBank	96.92	98.19	97.76	97.98	8.04	2.24	99.13	3.74
Network2	FBank+Δ	98.04	98.66	**98.90**	98.78	6.01	**1.10**	99.60	2.61
Network2	FBank+$\Delta+\Delta^2$	98.11	98.75	98.89	98.82	5.57	1.11	99.63	2.47
Network2	MFCC	96.61	98.26	97.29	97.77	7.67	2.71	98.95	3.98
Network2	MFCC+Δ	97.97	98.62	98.85	98.73	6.18	1.15	99.55	2.66

其中，Network1 为基础 MLP，结构如上文所述（第 3.2.2 节）；Network2 为批量实验配置中的 MLP 变体，在 Network1 的隐藏层后加入 BatchNorm 与 Dropout，用于增强训练稳定性并缓解过拟合。

在 10 轮训练设置下，Network1 + FBank+$\Delta+\Delta^2$ 取得较优整体性能。进一步延长训练至 40 轮，并保持左右各 1 帧上下文后，本实验对两个较强的 Network1 配置进行单独比较，结果如表 5。最终测试集的预测标签也基于最佳模型配置生成。

表 5: *Task2 DNN $\mathcal{D}_{dev}$ 40 轮训练结果（%）*

网络	特征	Acc	Prec	Rec	F_1	FAR	FRR	AUC	EER
Network1	FBank+Δ	98.07	98.73	98.84	98.79	5.65	1.16	99.61	2.57
Network1	FBank+$\Delta+\Delta^2$	**98.16**	**98.78**	**98.90**	**98.84**	**5.43**	**1.10**	**99.63**	**2.48**

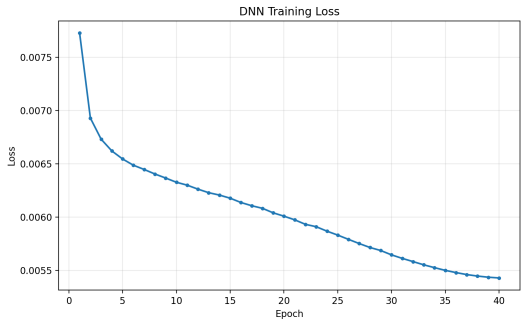

图 6: *DNN 最终配置（Network1，FBank+$\Delta+\Delta^2$，40 轮训练）的训练损失曲线。*

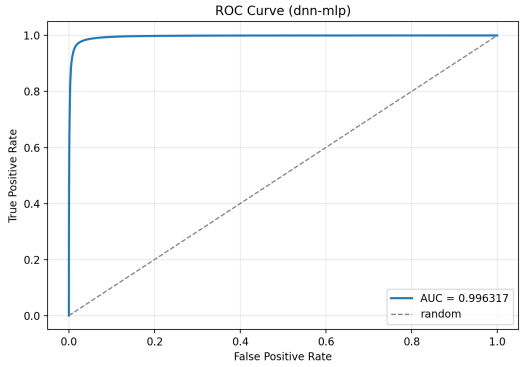

图 7: *DNN 最终配置（Network1，FBank+$\Delta+\Delta^2$，40 轮训练）的 $\mathcal{D}_{dev}$ ROC 曲线。*

从表 5 可以看到，新 40 轮配置在 Acc、Recall、F_1、FAR、FRR、AUC 与 EER 上均优于旧 40 轮配置，因此本实验最终 DNN 配置采用 Network1 + FBank+$\Delta+\Delta^2$。与 GMM 相比，DNN 在整体准确率和 AUC 上均有明显提升，说明判别式模型能更充分利用频域动态特征。加入差分特征和上下文帧信息能够显著提高模型预测准确率，说明端点检测需要利用相邻帧的时序连续性辅助判断。